

Dr.Öğr.Üyesi Furkan Göz

2025

- Python ile temel kodlama
- Veri türleri ve tip dönüşümleri
- Koşullar ve döngüler
- Basit yapay zeka projelerinin temelleri
- Çalışma ortamımız: Google Colab

- Tarayıcıda çalışan bir Python editörüdür  
→ Bilgisayar farkı gözetmeksizin kullanılabilir
- Bilgisayara kurulum gerekmez  
→ Hemen çalışmaya başlayabilirsiniz
- Kod hücreleriyle çalışılır (Shift + Enter)  
→ Kod ve metin içeriği aynı yerde yazılır
- Google Drive ile entegre çalışır  
→ Dosyalarınızı kaydedebilir, paylaşabilirsiniz
- [colab.research.google.com](https://colab.research.google.com)

### Not defterini aç

Örnekler >

Son açılanlar >

Google Drive >

GitHub >

Yükle >

Defterleri ara

Başlık

Overview of Colab Features

Markdown Guide

Charts in Colab

External data: Drive, Sheets, and Cloud Storage

Getting started with BigQuery

Forms

Data Table

+ Yeni not defteri

İptal

project1.ipynb ☆ ☁

Dosya Düzenle Göster Ekle Çalışma zamanı Araçlar Yardım

Komutlar + Kod + Metin ▶ Tümünü çalıştır

**Dosyalar**

- sample\_data

Kodlamaya başlayın veya yapay zeka ile kod oluşturun.

**Kaynaklar**

Abone değilsiniz. [Bilgi edinin](#)

Şu anda kullanılabilir işlem biriminiz yok. Ücretsiz olarak sunulan kaynaklar garantili değildir. [Buradan](#) daha fazla birim satın alabilirsiniz.

Bu çalışma zamanı mevcut kullanım düzeyinizde 100 saat kadar sürebilir.

[Oturumları yönet](#)

Daha fazla bellek ve disk alanı ister misiniz? [Colab Pro ürününe geç](#)

Python 3 Google Compute Engine arka uç 18:55 ile 18:57 arasındaki kaynaklar gösteriliyor

Sistem RAM'i	Disk
0.9 / 12.7 GB	37.7 / 107.7 GB

[Çalışma zamanı türünü değiştir](#)

Disk 70.04 GB kullanılabilir

Değişkenler Terminal

18:55 Python 3

- Donanım hızlandırıcısı (GPU/TPU) kullanmak için:
  - Menüden Çalışma Zamanı > Çalışma Zamanı Türünü Değiştir yolunu izleyin
  - Python sürümünü ve hızlandırıcısı seçin (CPU, GPU, TPU)
- Derin öğrenme gibi yoğun işlemler için GPU önerilir
- Ayarlar sonrası yeni çalışma zamanı başlatılır

Ek işlem birimleri satın alın'. At the bottom right, there are buttons for 'İptal' (Cancel) and 'Kaydet' (Save)." data-bbox="534 313 969 726"/>

Çalışma zamanı türünü değiştir

Çalışma zamanı türü

Python 3

Donanım hızlandırıcı ?

☒ CPU ☐ T4 GPU ☐ A100 GPU ☐ L4 GPU

☐ v2-8 TPU ☐ v6e-1 TPU ☐ v5e-1 TPU

Premium GPU'lara erişmek ister misiniz? [Ek işlem birimleri satın alın](#)

İptal Kaydet

```
1 print("Merhaba, Yapay Zeka!")
```

- `print()` komutu ekrana çıktı verir.
- Python'da ilk çalışan satır genellikle budur.
- Shift + Enter ile çalıştırabilirsiniz.

```
1 sayi = 42           # int
2 oran = 3.14         # float
3 isim = "Ayse"       # str
4 aktif = True        # bool
5 liste = [1, 2, 3]   # list
```

- Python değişkenlerde tür belirtmez, otomatik algılar.
- Temel veri tipleri: `int`, `float`, `str`, `bool`, `list`
- Yorum satırı: `#` ile başlar.



```
1  # Bir şehir adı (str)
2  # Doğum yılı (int)
3  # Ortalama puan (float)
4  # Üye mi? (bool)
5  # İlgi alanları listesi (list)
```

str → metin, int → tam sayı, float → ondalık, bool → True/False, list → köşeli parantezle diziler

```
1 x = "5"  
2 y = int(x)      # → 5  
3 z = float("2.5") # → 2.5  
4 isim = str(42)  # → "42"
```

- Metin → sayı dönüşümleri mümkündür
- `int("abc")` → Hata verir
- Dönüştürmeden önce veri tipi kontrol edilmeli

```
1 temperature = 32
2 if temperature > 30:
3     print("Too hot!")
4 elif temperature > 20:
5     print("Warm weather")
6 else:
7     print("Cool or cold")
```

- if / elif / else yapısı
- Duruma göre farklı çıktılar üretir

```
1 giris = input("Sayilari girin: ")
2 liste = giris.split(",")
3 sayilar = [float(x) for x in liste]
4 print("Ortalama:", sum(sayilar)/len(sayilar))
```

- `input()` ile kullanıcıdan veri alınır
- `split(",")` ile listeye dönüştürülür
- Liste üzerinde matematiksel işlem yapılabilir

```
1 temperature = float(input("Enter temperature: "))
2
3 if temperature < 0:
4     print("Below freezing!")
5 elif temperature < 20:
6     print("Cool day")
7 else:
8     print("Warm or hot")
```

```
1 boy = float(input("Boy (metre): "))
2 kilo = float(input("Kilo (kg): "))
3 bmi = kilo / (boy ** 2)
4
5 if bmi < 18.5:
6     print("Zayif")
7 elif bmi < 25:
8     print("Normal")
9 elif bmi < 30:
10    print("Fazla kilolu")
11 else:
12    print("Obez")
```

```
1 fruits = ["apple", "banana", "strawberry"]
2 for fruit in fruits:
3     print(fruit)
```

- Listedeki her eleman için işlem yapılır
- Dizi, liste, aralık vb. üzerinde çalışır

```
1 for i in range(11):  
2     if i % 2 == 0:  
3         print(i, "is even")  
4     else:  
5         print(i, "is odd")
```

- `range(11)` → 0'dan 10'a kadar sayılar üretir
- `%` operatörü: mod alma, yani kalanı bulma işlemidir
- `i % 2 == 0` → sayı çiftse doğru olur



```
1 i = 0
2 while i < 3:
3     print(i)
4     i += 1
```

- Koşul doğruysa döngü devam eder
- Sayaç değişkeni dikkatle yönetilmeli

- Kodu tekrar yazmak yerine, fonksiyonlarla modülerleştiririz.
- Girdi alabilir, çıktı döndürebilir.
- `def` anahtar kelimesi ile tanımlanır.

```
1 def selamla(isim):  
2     print("Merhaba,", isim)  
3  
4 selamla("Ayse")
```

- Fonksiyon çağrıldığında belirli bir işi yapar.
- Parametre alabilir (örnek: `isim`).

```
1 def ortalama(liste):  
2     return sum(liste) / len(liste)  
3  
4 puanlar = [80, 90, 75]  
5 print("Ortalama:", ortalama(puanlar))
```

- **return** ile çıktı geri döndürülür.
- Fonksiyon başka işlemler için tekrar kullanılabilir.

```
1 try:
2     sayi = int(input("Bir sayı girin: "))
3     print("Karesi:", sayi ** 2)
4 except ValueError:
5     print("Lütfen geçerli bir tam sayı girin!")
```

- try bloğu: Hata oluşabilecek kod.
- except bloğu: Hata oluşursa ne yapılacağını belirtir.

```
1 import pandas as pd
2 try:
3     df = pd.read_csv("veri.csv")
4     print(df.head())
5 except FileNotFoundError:
6     print("Dosya bulunamadi. Lutfen yolunu kontrol edin.")
```

- Dosya işlemleri sırasında sıkça kullanılır.
- Programın durması engellenir, kullanıcı bilgilendirilir.

- Python'da 4 temel koleksiyon tipi vardır:
  - List – sıralı, değiştirilebilir
  - Tuple – sıralı, değiştirilemez
  - Set – benzersiz elemanlar, sırasız
  - Dict – anahtar-değer çiftleri
- Veri işleme ve analizde bu yapılar sıkça kullanılır

```
1 meyveler = ["elma", "muz", "çilek"]    # list
2 koordinat = (10, 20)                   # tuple
3 renkler = {"kirmizi", "mavi"}           # set
4 ogrenci = {"ad": "Ali", "yas": 21}      # dict
```

- list: Değiştirilebilir, sıralı
- tuple: Sabit yapılar
- set: Tekrarsız veri
- dict: Etiketlenmiş veri (anahtar/değer)



```
1 ogrenci = {"ad": "Zeynep", "not": 85}
2
3 print(ogrenci["ad"])           # Zeynep
4 ogrenci["not"] += 5            # Notu 1 artır
5 print(ogrenci["not"])          # 90
```

- Anahtarlar string veya sayısal olabilir.
- Veri analizi sırasında JSON ve tablo verileri sözlüklerle temsil edilir.

- NumPy dizileri hızlı ve verimli hesaplamalar sağlar.
- Vektör, matris ve çok boyutlu dizilerle çalışılır.
- Rastgele sayı üretimi, istatistiksel işlemler ve matris çarpımı yapılabilir.

```
1 import numpy as np
2
3 dizi = np.array([1, 2, 3, 4])
4 print(dizi)
5
6 aralik = np.arange(0, 10, 2)
7 print(aralik)
```

- `np.array()` ile liste dizisine dönüştürme
- `np.arange(start, stop, step)` ile sayı üretme

```
1 a = np.array([1, 2, 3])
2 b = np.array([4, 5, 6])
3
4 toplam = a + b
5 ortalama = np.mean(toplam)
6 print(ortalama)
```

- Diziler arasında doğrudan matematiksel işlem yapılabilir
- `np.mean()` ile ortalama alınabilir

```
1 import numpy as np
2
3 print("Tam sayi:", np.random.randint(0, 10, size=3)) # 0-9
   arasi 3 adet
4 print("0-1 arasi:", np.random.rand(3)) #
   [0,1) arasi
5 print("Normal dagilim:", np.random.randn(3))
```

- `randint()` → belirtilen aralıkta tamsayı üretir.
- `rand()` → 0 ile 1 arasında eş dağılımlı sayı üretir.
- `randn()` → normal dağılıma göre rastgele sayı üretir.

```
1 import numpy as np
2
3 meyveler = ["elma", "armut", "muz"]
4 print("Rastgele secim:", np.random.choice(meyveler))
5
6 a = np.array([1, 2, 3, 4])
7 np.random.shuffle(a)
8 print("Karistirilmis:", a)
```

- `choice()` → bir listeden rastgele seçim yapar.
- `shuffle()` → dizinin elemanlarını yerinde karıştırır.
- Simülasyon ve test senaryoları için sıkça kullanılır.

```
1 veri = np.array([10, 20, 30, 40])  
2  
3 print("Toplam:", np.sum(veri))  
4 print("Ortalama:", np.mean(veri))  
5 print("Std Sapma:", np.std(veri))
```

- `sum`, `mean`, `std` gibi fonksiyonlar hızlı hesaplama sağlar.
- İstatistiksel analizlerin temeli atılır.

```
1 a = np.array([[1, 2], [3, 4]])  
2 b = np.array([[5, 6], [7, 8]])  
3  
4 carpim = np.dot(a, b)  
5 print(carpim)
```

- `dot()` ile matris çarpımı yapılır.
- Derin öğrenme gibi alanlarda temel yapı taşlarındandır.



```
1 import numpy as np
2 a = np.arange(6)
3 print(a.reshape((2, 3)))
```

- `reshape()` diziyi 2 boyutlu hale getirir

```
1 import pandas as pd
2
3 veri = {
4     "isim": ["Ayse", "Ali", "Zeynep"],
5     "yas": [23, 34, 29]
6 }
7 df = pd.DataFrame(veri)
8 print(df)
```

- `pd.DataFrame` tablo benzeri veri yapısı oluşturur
- Sözlük yapısı → satır/sütun yapısına dönüştürülür

```
1 df = pd.DataFrame({  
2     "kategori": ["A", "B", "A", "C", "B", "A"]  
3 })  
4  
5 print(df["kategori"].value_counts())
```

- `value_counts()` → Kategorilerin sıklığını verir
- Görselleştirme öncesi anlamlı içgörü sağlar

```
1 yasli = df[df["yas"] > 30]
2 print(yasli)
```

- Sadece belirli koşulu sağlayan satırlar seçilebilir
- `df[df["sütun"] > değer]` yapısı kullanılır

```
1 veri = {  
2     "cinsiyet": ["K", "E", "K", "E"],  
3     "puan": [85, 70, 90, 60]  
4 }  
5 df = pd.DataFrame(veri)  
6 grup = df.groupby("cinsiyet")["puan"].mean()  
7 print(grup)
```

- groupby() ile veriler gruplanabilir
- Her grup için ortalama gibi işlemler yapılabilir

- Matplotlib ile grafiklerde başlık, etiket, renk, stil ekleyebiliriz.
- Seaborn ile estetik ve anlamlı görseller kolayca oluşturulur.
- Grafikler veriyi daha anlaşılır ve etkili hale getirir.

```
1 import matplotlib.pyplot as plt
2 gunler = ["Pzt", "Sal", "Car"]
3 satis = [100, 150, 90]
4 plt.plot(gunler, satis, marker='o', color='green',
5          linestyle='--')
6 plt.title("Günlük İş Satlar")
7 plt.xlabel("Gun")
8 plt.ylabel("Satis")
9 plt.grid(True)
10 plt.show()
```

- **marker**, **color**, **linestyle** ile stil verilebilir. Başlık ve eksen etiketleri okunabilirliği artırır.

```
1 import seaborn as sns
2 import pandas as pd
3
4 df = pd.DataFrame({
5     "kategori": ["A", "B", "A", "C", "B", "A"]
6 })
7
8 sns.countplot(x="kategori", data=df)
```

■ countplot → kategorik verilerin sıklığını görselleştirir.



```
1 data = {  
2     "urun": ["Kalem", "Defter", "Kalem", "Silgi"],  
3     "adet": [10, 5, 8, 3],  
4     "fiyat": [2.5, 5.0, 2.5, 1.0]  
5 }  
6  
7  
8 df = pd.DataFrame(data)  
9 df["toplam"] = df["adet"] * df["fiyat"]  
10  
11 print(df.groupby("urun")["toplam"].sum())
```

- Veri çerçevesi oluşturma, Yeni sütun hesaplama, Ürün bazında toplam satış analizi

- Gerçek veri setlerinde eksik gözlemler çok yaygındır.
- Nedenleri:
  - Katılımcı bazı soruları boş bırakmış olabilir.
  - Sensörler hata verip ölçüm yapmamış olabilir.
  - Veri aktarımı sırasında bilgi kaybolmuş olabilir.
- Eksik veriler analiz sonuçlarını bozabilir, dikkatle ele alınmalıdır.

- Gerçek veri setlerinde eksik değerler kaçınılmazdır.
- `isna()`, `fillna()`, `dropna()` ile eksik veriler analiz edilir.
- Eksik verileri silmek yerine, ortalama veya medyan gibi stratejilerle doldurmak daha etkilidir.
- Görsel analiz için ısı haritası (heatmap) kullanılabilir.

```
1 import pandas as pd
2
3 df = pd.DataFrame({
4     "ad": ["Ali", "Ayse", "Mehmet", "Zeynep"],
5     "yas": [25, None, 40, None],
6     "puan": [85, 90, None, 75]
7 })
8
9 print(df.isna())
10 print(df.isna().sum())
```

- `isna()` → Boolean tablo: True = eksik
- `sum()` → eksik değer sayısını verir

```
1 ortalama = df["yas"].mean()  
2 df["yas"] = df["yas"].fillna(ortalama)  
3 print(df)
```

- `fillna()` ile boş hücreler doldurulur.
- Ortalama, medyan veya sabit bir değer kullanılabilir.

```
1 import seaborn as sns
2 import matplotlib.pyplot as plt
3
4 sns.heatmap(df.isna(), cbar=False, cmap="Reds")
5 plt.title("Eksik Veri Haritası")
6 plt.show()
```

- Isı haritası ile hangi satır/sütunlarda eksik veri olduğu kolayca görülür.
- Özellikle büyük veri setlerinde çok faydalıdır.



```
1 df = pd.DataFrame({
2     "ad": ["Ali", "Zeynep", "Ayse"],
3     "yas": [25, 22, 30],
4     "puan": [80, 90, 75]
5 })
6
7 secim = df[(df["yas"] > 23) & (df["puan"] > 70)]
8 print(secim)
```

- Birden fazla koşul kullanılabilir: &, |
- Parantez kullanımı zorunludur!



- Bar (çubuk): Kategorik veriler (ürün satışları)
- Line (çizgi): Zaman serileri (günlük sıcaklık)
- Histogram (hist): Sayısal dağılım (puan dağılımı)

```
1 df = pd.DataFrame({  
2     "gun": ["Pzt", "Sal", "Çar"],  
3     "satis": [100, 150, 90]  
4 })  
5 df.plot(kind="bar", x="gun", y="satis")  
6 df.plot(kind="line", x="gun", y="satis")
```


## Bar Grafiği

- Kategorik veriler için uygundur
- Ürün, şehir, gün gibi sınıflar
- Değerler ayrı ayrı çubukla


## Çizgi Grafiği

- Zamanla değişimi gösterir
- Trend ve artış/azalış analizleri
- Noktalar bir çizgiyle birleştirilir

## Bar Grafiği




## Çizgi Grafiği



- Bar grafikte her günün satış değeri ayrı çubukla gösterilir
- Çizgi grafik, satışların trendini daha net ortaya koyar

```
1 import matplotlib.pyplot as plt
2 veriler = [60, 70, 80, 85, 90, 70, 75]
3 plt.hist(veriler, bins=5)
4 plt.title("Not Dağılımı")
5 plt.show()
```

- Histogram → Sayısal verilerin dağılımını gösterir
- bins: Kaç aralıkta gruplandırılacağı



- CSV ve JSON dosyaları veri bilimi projelerinde en sık kullanılan formatlardır.
- Gerçek projelerde karşılaşılan zorluklar:
  - Farklı ayırıcılar (örneğin: ; veya |)
  - Dosya karakter kodlamaları (UTF-8, ISO-8859-9)
  - JSON dosyalarında iç içe geçmiş yapılar (nested)

```
1 df = pd.read_csv("veri.csv", sep=";", encoding="utf-8")  
2 print(df.head())
```

- `sep=";"` → Noktalı virgülle ayrılmış dosyalar için
- `encoding="utf-8"` → Türkçe karakterler için yaygın

```
1 df = pd.read_csv("veri.csv")  
2 print(df.head())
```

- CSV: Virgülle ayrılmış tablo dosyası
- `read_csv()` ile kolayca yüklenir
- İlk satırlar için `head()` fonksiyonu kullanılır

```
1 json_data = [  
2     {"ad": "Ali", "adres": {"sehir": "Ankara", "posta":  
3         6000}},  
4     {"ad": "Zeynep", "adres": {"sehir": "İzmir", "posta":  
        3500}}  
]
```

- Bu tür veri `pd.read_json()` ile doğrudan düzgün yapılamaz.
- Nested yapılar `json_normalize()` ile düzenlenmelidir.



```
1 import pandas as pd
2 from pandas import json_normalize
3
4 df = json_normalize(json_data)
5 print(df)
```

- `json_normalize()` → iç içe geçmiş JSON'u tablolara dönüştürür.
- Kolon isimleri: `adres.sehir`, `adres.posta` gibi olur.

```
1 df = pd.read_json("veri.json")  
2 print(df)
```

- JSON: Sözlük benzeri veri formatı (anahtar-değer)
- Genellikle API'lerden veri çekerken kullanılır
- `read_json()` ile yüklenebilir

```
1  [  
2    {"ad": "Ayse", "yas": 25},  
3    {"ad": "Ali", "yas": 30}  
4  ]
```

- JSON yapısı: Liste içinde sözlükler
- Her sözlük bir satırı temsil eder

- Veriyi sadece görselleştirmek değil, anlamlandırmak da önemlidir.
- Satış, kategori ya da zaman trendleri üzerine yorum yapılmalı.
- Öğrenci çıkarım yapabilmeli: "Neden bu gün daha çok satıldı?"
- Bu beceri veri okuryazarlığı ve yapay zeka için kritik önemdedir.

```
1 import pandas as pd
2
3 df = pd.read_csv("satilar.csv")
4 df["toplam"] = df["miktar"] * df["birim_fiyat"]
5
6 kategori_sat = df.groupby("kategori")["toplam"].sum()
7 print(kategori_sat)
```

- Soru: En çok satış yapılan kategori neden bu kadar yüksek?
- O kategoriye özel kampanya mı vardı? Daha pahalı ürünler mi?

```
1 df["tarih"] = pd.to_datetime(df["tarih"])
2 gunluk = df.groupby("tarih")["toplam"].sum()
3
4 print(gunluk.idxmax(), "gunu en cok satis yapildi.")
```

- Soru: En çok satış yapılan gün hangisi?
- Cevap: `idxmax()` → En yüksek değerin tarihi
- Yorum: Hafta sonu mu? Kampanya dönemi mi?

- “Satışlar hafta ortasında düşüyor, cuma tekrar artıyor.”
- “Elektronik kategorisi yüksek, çünkü ürün başı fiyatlar yüksek.”
- “Hafta sonu satış artışı → müşterilerin alışveriş alışkanlığı”
- Yorum yapabilmek = veriden değer üretmek

Analitik düşünme yetkinliği = Veri bilimi ve yapay zeka için temel beceridir.

- Makine öğrenmesi modelleri sayısal verilerle çalışır.
- Kategorik veriler sayıya çevrilmeli, sayısal veriler ölçeklenmelidir.
- Bu adımlar model başarısını ve yorumlanabilirliği artırır.



```
1 import pandas as pd
2
3 df = pd.DataFrame({
4     "cinsiyet": ["E", "K", "K", "E"]
5 })
6
7 df_kodlu = pd.get_dummies(df, columns=["cinsiyet"], dtype=
8     int)
9 print(df_kodlu)
```

- `get_dummies()` → kategorik sütunları 0/1 vektörlerine dönüştürür.
- Özellikle "erkek/kadın" gibi sınıflarda kullanılır.

- Farklı ölçeklerdeki veriler model öğrenmesini olumsuz etkiler.
  - Örnek: `gelir` ( 1000– 100000) ve `yaş` (18–65)
- Büyük değerler, küçük değerleri baskılayabilir.
- Özellikle mesafe tabanlı algoritmalarda (kNN, K-Means) bu durum çok önemlidir.
- Normalleştirme sayesinde:
  - Tüm değişkenler benzer ölçeğe gelir.
  - Model daha hızlı ve dengeli öğrenir.
  - Eğitim süresi kısalır, ağırlık öğrenimi istikrarlı olur.

```
1 from sklearn.preprocessing import MinMaxScaler
2
3 veri = [[50], [80], [100]]
4 scaler = MinMaxScaler()
5 normal = scaler.fit_transform(veri)
6
7 print(normal)
```

- MinMaxScaler verileri 0-1 aralığına çeker.
- Modelin daha hızlı ve kararlı öğrenmesini sağlar.

```
1 from sklearn.preprocessing import StandardScaler
2
3 veri = [[60], [70], [80]]
4 scaler = StandardScaler()
5 zskor = scaler.fit_transform(veri)
6
7 print(zskor)
```

- **StandardScaler** → ortalaması 0, std sapması 1 olacak şekilde dönüştürür.
- Özellikle mesafe tabanlı algoritmalarda önemlidir.

- İstatistiksel özetler, verinin yapısını anlamamızı sağlar.
- Ortalama, medyan, varyans, standart sapma, korelasyon gibi metrikler incelenmelidir.
- Bu bilgiler, model seçimi ve yorumlamada yol gösterir.

```
1 import numpy as np
2
3 veri = [50, 55, 60, 100]
4
5 print("Medyan:", np.median(veri))
6 print("Varyans:", np.var(veri))
7 print("Standart Sapma:", np.std(veri))
```

- `median()` → ortadaki değer
- `var()`, `std()` → veri yayılımını ölçer

```
1 import pandas as pd
2
3 df = pd.DataFrame({
4     "yas": [20, 30, 40, 35],
5     "puan": [80, 70, 90, 85]
6 })
7
8 print(df.describe())
```

- `describe()` → sayısal sütunların genel özetini verir.
- Ort., min, max, çeyrek değerler gibi birçok ölçütü otomatik verir.

- ! ile Linux terminal komutları çalıştırılabilir
  - !pwd → Mevcut klasörü gösterir
  - !ls /content/ → Dosyaları listeler
  - !nvidia-smi → GPU varsa özelliklerini gösterir
- Ortamı tanımak ve kontrol etmek için kullanışlıdır



```
1 from google.colab import drive
2 drive.mount('/content/drive')
3
4 !ls /content/drive/MyDrive/
5 %cd /content/drive/MyDrive/projeler/
```

- `drive.mount()` ile Drive bağlanır
- `!ls` → Klasör içeriği listelenir
- `%cd` → İlgili klasöre geçiş yapılır

```
1 import pandas as pd
2
3 df = pd.read_csv("titanic.csv")
4 print(df.head())
```

- Titanic yolcu verisi: yaş, cinsiyet, sınıf, hayatta kalma
- `read_csv()` ile dosya yüklenir
- `head()` ile ilk 5 satır görüntülenir

```
1 print(df.isna().sum())
```

- Bazı sütunlarda eksik değer olabilir
- Bu veriler doldurulabilir, silinebilir ya da göz ardı edilebilir
- `isna().sum()` → kaç eksik olduğunu gösterir

```
1  kadınlar = df[df["Sex"] == "female"]  
2  yetiskinler = df[df["Age"] > 30]  
3  birinci_sinif = df[df["Pclass"] == 1]
```

- Cinsiyet, yaş ve sınıfa göre filtreleme örnekleri
- Bu filtrelerle veri segmentasyonu yapılabilir


```
1 oran = df["Survived"].mean()  
2 print("Genel hayatta kalma oranı:", oran)  
3  
4 #float((df["Survived"] == 1).sum()/df["Survived"].size)
```

- Survived: 0 = öldü, 1 = hayatta kaldı
- Ortalama hayatta kalma oranını verir
- Grup bazlı oranlar da yapılabilir

1

```
df.groupby("Sex")["Survived"].mean().plot(kind="bar")
```

- Cinsiyete göre hayatta kalma oranı
- Bar grafikle fark kolayca görülür



- Gerçek bir veri setini inceledik (titanic.csv)
- Eksik verileri kontrol ettik
- Koşullu filtreleme uyguladık
- Ortalama hayatta kalma oranını hesapladık
- Grup bazlı grafiklerle sonuçları görselleştirdik

Veri Seti: `satislar.csv` dosyasını kullanarak aşağıdaki adımları takip ediniz.

- 1 Veriyi oku: `pandas` ile dosyayı içe aktar.
- 2 İlk inceleme: `head()`, `info()`, `describe()` ile yapıyı tanı.
- 3 Eksik değerleri tespit et: Hangi sütunlarda eksik var? Kaç adet?
- 4 Eksik değerleri doldur: `adet` ve `fiyat` sütunlarını ortalama ile doldur.
- 5 Yeni sütun oluştur: `toplam = adet * fiyat`
- 6 Kategori bazlı analiz: `groupby()` ile toplam satışları hesapla, bar grafik çiz.
- 7 Günlük satış trendi: `tarikh` sütununu dönüştür ve çizgi grafikte göster.
- 8 Şehir bazlı analiz: Hangi şehirde satış daha fazla? Bar grafikte sun.
- 9 Ödeme tipi analizi: Hangi ödeme türü daha yaygın? `countplot` çiz.



Veri Seti: `ogrenci_notlari.csv` dosyasını analiz ederek aşağıdaki işlemleri uygulayınız:

- 1 Veriyi oku ve ilk 5 satırı görüntüle.
- 2 Eksik notları tespit et ve ortalama ile doldur.
- 3 Başarı notu hesapla: Vize %40, Final %60.
- 4 Geçti/Kaldı sınıflandırması yap. Notu 50 ve üzeri olanlar geçti.
- 5 Her ders için ortalama başarıyı hesapla ve bar grafiklerle göster.
- 6 Devamsızlık dağılımını histogram grafiği ile çiz.
- 7 Yorum yap:
  - En düşük başarı hangi derste?
  - Devamsızlık başarıyı etkiliyor mu?
  - Sınıfta kaç kişi geçti/kaldı?